Prueba y Evaluación de un Algoritmo Genético Simple

José Adrián Rodríguez González
Campus Irapuato-Salamanca
Ingeniería en datos e Inteligencia Artificial
Marzo 2026

***Abstract*—En este trabajo se evalúa el desempeño de un algoritmo genético simple aplicado a la maximización de una función no lineal de dos variables. Se analiza el efecto de la sintonización de parámetros y el comportamiento del algoritmo en un espacio de búsqueda continuo.**

I. Introducción

Los algoritmos genéticos son técnicas de optimización inspiradas en la evolución natural. Son especialmente útiles en problemas donde la función objetivo es compleja, multimodal o no diferenciable. En este trabajo, se reportan los resultados obtenidos por el algoritmo implementado en clase para la función no linear siguiente:

$$f(x,y) = 10e^{-((x^2+y^2)/20)} + \cos(2x) + \sin(2y) \qquad (1)$$

dentro del dominio:

$$-6.28 \leq x \leq 6.28, \quad -6.28 \leq y \leq 6.28$$

II. Visualización de la función

A continuación se muestra la gráfica de la función objetivo:

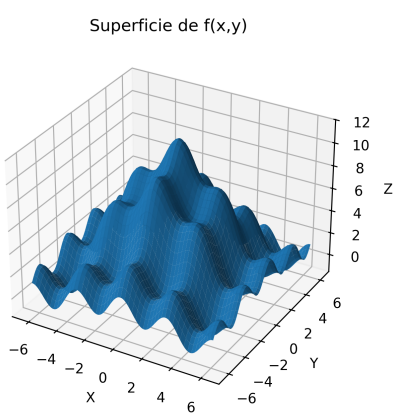

Fig. 1. Función no lineal

Como podemos observar en la gráfica es una función multimodal y no lineal. Al analizar la función, tenemos primeramente una función gaussiana, y que si solo fuera eso, teóricamente el problema no sería tan complejo, sin embargo, las funciones seno y coseno meten el ruido de generar surcos y valles al rededor del campo de optimización. De esta manera, se generan varios máximos locales que un algoritmo como el gradiente de descenso puro, o algoritmos de optimización clásicos, caerían facilmente en este tipo de valores locales. Por lo tanto, El algoritmo genético resulta conveniente para este tipo de problemas.

III. Representación del problema

El problema se modela utilizando un algoritmo genético donde cada individuo representa un par (x, y). Cada variable es un cromosoma dentro del gen. Y cada cromosoma tiene la longitud de 16 bit. Como se menciono, la codificación se hace de manera binaria, sin embargo, esta codificación binaria se traduce a un valor en flotante que será el que nos ayudara a encontrar el valor de fitness. Adicionalmente, se deben de tomar en cuenta las restricciones del dominio de los valores en (x, y). A manera de recapitular, el algoritmo genético, está descrito de la siguiente manera(Algorithm.1).

IV. Sintonización de parámetros

Se ajustaron los siguientes parámetros:

- Tamaño de población: 100
- Probabilidad de cruce: 0.9
- Probabilidad de mutación:0.015
- Número de generaciones:1000

Con estos valores, que inclusive, se pudieron ver en el algoritmo 1. Este ajuste de parámetro siguió la estrategia vista en clase con respecto al cambio primordial de tamaño de individuos y número de generaciones y que en cada uno de esos cambios, se hagan ajustes a los valores de probabilidad de cruza y mutación.

V. Resultados

Se obtuvo un valor máximo de 11.471 con los valores $x \approx -0.162426, y \approx 3.79943$, sin embargo, no es conveniente solo quedarse con el resultado de un resultado, así que se realizaron 10 pruebas en dos iteraciones, por lo que los resultados de la tabla I, muestran el promedio de los valores $x, y, f(x,y), fitness$ para nuestro problema. Por lo que podemos decir que la esperanza matemática se expresa para la primera variable $\mathbb{E}[x] = -0.162855$, para la segunda variable $\mathbb{E}[y] = 3.799525$, de la función $\mathbb{E}][f(x,y)] = 11.471$ y del valor de fitness es 99.99, la desviación resulta ser de $\sigma[y] = 0.000285$ para la primera variable y $\sigma[x] = 0.000045$,

Algorithm 1 Algoritmo Genético para la optimización de $f(x, y)$

```
Inicializar contador de generaciones t ← 1
Definir número de bits por variable: NUMBITS = {16, 16}
Definir límites inferiores l_i = {−6.28, −6.28}
Definir límites superiores l_s = {6.28, 6.28}
Inicializar población GA(100, 2, NUMBITS, l_i, l_s)
Decodificar población a enteros
Decodificar población a valores reales
Evaluar población
Convertir función objetivo a fitness (maximización)
while t ≤ MAX_GENERACIONES do
    Selección por ruleta
    Cruza de un punto con probabilidad 0.90
    Mutación con probabilidad 0.015
    Aplicar elitismo
    Generar nueva población
    Decodificar población a enteros
    Decodificar población a valores reales
    Evaluar población
    Convertir función objetivo a fitness
    t ← t + 1
end while
Imprimir mejor individuo encontrado
```

indicando que se logró una alta estabilidad y que el algoritmo por lo tanto, logró converger

Run	y	x	$f(x, y)$	Fitness
1–10	3.79981	-0.16281	11.471	99.9999
11–20	3.79924	-0.16290	11.471	99.9998–99.9999

TABLE I
RESULTADOS DEL ALGORITMO GENÉTICO EN MÚLTIPLES EJECUCIONES

VI. CONCLUSIONES

El algoritmo genético mostró ser robusto ante el problema que se presentaba con la función, que, como se menciona, posee varios picos de máximos locales, sin embargo, a pesar de ese inconveniente, el algoritmo logró consolidarse con los valores de $f(-0.162855, 3.799525) = 11.471$, siendo así, la función descrita completamente junto a su valor máximo